




Автоматическая оценка удобочитаемости русскоязычных текстов

Студентка: Пучкова Е.М., 425,
Научный руководитель: Головин И.Г.



Актуальность работы

Удобочитаемость – характеристика текста, основанная на количественных параметрах: количество слов в предложении, количество знаков или слогов в слове, количество слов, состоящих из трёх и более слогов и другие

Оценка удобочитаемости текстов применяется для:

- повышения качества публикуемых текстов
- экспертизы школьных учебников, экзаменационных текстов, других дидактических материалов
- подготовки деловой документации
- подготовки текстов нормативно-правовых актов

Постановка задачи

1. Проанализировать существующие подходы к решению задачи и соответствующие им модели и алгоритмы
2. Разработать набор данных для проверки моделей оценки удобочитаемости текстов
3. Выбрать множество методов и моделей классификации для последующей оценки
4. Оценить качество работы моделей на разработанном наборе данных, сравнить его с существующими аналогами и выбрать наилучшую модель и набор ее параметров
5. Разработать программу автоматической оценки удобочитаемости, основанную на выбранном варианте

Plain Russian Language. Модели для сравнения

- Для сравнения – формулы оценки удобочитаемости из проекта Plain Russian Language
- Адаптированы 5 классических метрик оценки удобочитаемости: Flesh Kinkaid rus, Flesh Kincaid Grade rus, SMOG Index, Dale Chale Index, ARI Index
- Осуществлялось подсчитывание значения accuracy для каждой формулы

Точность формул, разработанных в рамках проекта Plain Russian Language

Метрика удобочитаемости	accuracy_score
Метрика Flesh Kinkaid rus	0.157
Метрика Flesh_Kincaid_Grade_rus	0.315
Метрика Flesh_Kincaid_Grade_rus_flex	0.218
Метрика SMOG Index	0.127
Метрика Dale Chale Index	0.175
Метрика ARI Index	0.272

Разработка датасета

- 4 уровня удобочитаемости текстов: 1-4 класс, 5-9 класс, 10-11 класс, старше 11 класса
- Из учебников и презентаций:
 - тексты 1-3 уровней – из презентаций для школьников, 4 уровня – из текстов методических пособий, учебников для ВУЗов
 - для каждого уровня удобочитаемости – 20 текстов. Общее количество текстов – 80
- Из проекта Plain Russian Language и текстов диктантов из дидактических материалов:
 - размер датасета - 200 текстов (181523 предложений)

Формирование множества признаков

- Примеры признаков:
 - количество предложений
 - количество слов, обладающих конкретной граммемой
 - количество слогов в тексте
- Общее количество признаков – 50000
- Необходимо уменьшить количество признаков

ПОДГОТОВКА ДАННЫХ

- Отбор признаков на основе:
 - коэффициента в формуле линейной регрессии
 - корреляции признака и столбца целевой переменной
- Нормализация данных:

- MinMaxScaler:

$$X_{std} = \frac{X - X_{min}}{X_{max} - X_{min}} ; X_{scaled} = X_{std} \cdot (\max - \min) + \min$$

- StandardScaler:

$$X_{scaled} = \frac{X - mean}{std}$$

Алгоритмы

Модели из библиотеки sklearn:

- деревья решений
- логистическая регрессия с использованием подхода «один-против-всех» (one-vs-rest)
- гауссовский наивный Байес (GaussianNB)
- ближайший центроид (NearestCentroid)

Эксперименты

- Отбор признаков: коэффициент корреляции, значение коэффициента в формуле линейной регрессии
- Нормализация данных: MinMaxScaler, StandardScaler
- Количество признаков: $1, \dots, 100$
- Алгоритмы: логистическая регрессия, гауссовский наивный Байес, метод ближайшего центроида, деревья решения
- Всего – 1600 экспериментов

Результаты экспериментов

Номер	Метод предобработки данных	Критерий отбора признаков	Алгоритм	Количество признаков	accuracy score
1	StandardScaler	Линейная Регрессия	Logistic Regression	85	0.509
2			GaussianNB	90	0.345
3			KNeighborsClassifier	31	0.472
4			DecisionTreeClassifier	60	0.545
5		correlation ratio	Logistic Regression	72	0.472
6			GaussianNB	10	0.527
7			KNeighborsClassifier	59	0.636
8			DecisionTreeClassifier	12	0.690
9	MinMaxScaler	Линейная Регрессия	Logistic Regression	91	0.581
10			GaussianNB	90	0.345
11			KNeighborsClassifier	32	0.472
12			DecisionTreeClassifier	46	0.545
13		correlation ratio	Logistic Regression	90	0.436
14			GaussianNB	10	0.527
15			KNeighborsClassifier	59	0.618
16			DecisionTreeClassifier	97	0.654

Сравнение с классическими метриками

	Метрика удобочитаемости	accuracy
Метрики на основе формул из Plain Russian Language	Flesh_Kinkaid_rus	0.157
	Flesh_Kincaid_Grade_rus	0.315
	Flesh_Kincaid_Grade_rus_flex	0.218
	SMOG Index	0.127
	Dale Chale Index	0.175
	ARI Index	0.272
Модель машинного обучения	Standard Scaler, Decision Tree, correlation ratio 12 признаков	0.690

Программа оценки удобочитаемости

- Разработана консольная программа на языке Python
- Применена модель с наилучшим accuracy:
 - Алгоритм: классификация по методу решающих деревьев
 - Способ нормализации: StandardScaler
 - Отбор признаков: коэффициент корреляции между признаком и столбцом целевой переменной
 - Количество признаков: 12

Основные результаты работы

1. На основе методических материалов разработан набор данных, ранжированный по 4 классам сложности
2. Проведена серия экспериментов по сравнению качества различных моделей классификации с использованием разработанного датасета
3. На основе модели, показавшей наилучшее качество из рассмотренных, разработана программа для оценки удобочитаемости текстов на русском языке



Спасибо за внимание!

Удобочитаемость

- Сложность текста – многоаспектное понятие, ряд аспектов трудно формализуем и не поддается подсчету на компьютере
- Удобочитаемость интуитивно коррелирует со сложностью
- Удобочитаемости можно дать количественную оценку

Нормализация данных

- MinMaxScaler

- приводит признаки к заданному диапазону(Например, от 0 до 1)
- преобразование происходит по следующим формулам:

$$X_{std} = \frac{X - X_{min}}{X_{max} - X_{min}}; X_{scaled} = X_{std} \cdot (\max - \min + \min)$$

- StandardScaler

- приводит признаки к нулевому среднему и единичной дисперсии
- преобразование происходит по следующей формуле:

$$X_{scaled} = \frac{X - mean}{std}$$